

HUO BOXS · AI & Data Portfolio



AI 应用开发 · AI Agent / RAG · 深度学习 · 数据分析

信计专业本科生，围绕 LLM 应用、RAG / Agent、机器学习与数据分析持续做项目实践，重点关注“能运行、可验证、可解释、可落地”。

方向	项目	关键词
AI 应用 / RAG	Enterprise RAG	Hybrid Retrieval · Rerank · FastAPI · Ollama · Docker
AI Product	FinPilot	LLM · Structured Output · Rule Engine · Taro · SQLite
数据分析	电商经营数据分析	Python · SQL · Power BI · RFM · Dashboard
AI 算法	医疗 AI 细胞分类	PyTorch · CNN / ViT · 多模型实验 · 模型评估

Project 01 | 电商经营数据分析平台

定位：数据分析 / 商业分析 / BI

围绕电商经营数据完成 数据清洗 → 指标体系 → 用户分析 → Power BI Dashboard → 经营洞察。

Analysis Flow

1	原始数据 → 数据清洗 → 指标体系 → Overview
2	↓
3	用户行为分析 → RFM 分层
4	↓
5	Dashboard → 洞察

Dashboard



RFM Analysis



维度	含义	关注问题
R	最近一次消费	用户是否仍活跃
F	消费频次	用户是否稳定消费
M	消费金额	用户价值贡献

核心能力

- 数据处理：清洗、字段处理、分析数据集构建。
- 指标设计：经营、交易、用户等维度指标拆解。
- 用户分析：RFM 用户价值分层。
- BI 可视化：Overview、用户分析 Dashboard。
- 业务分析：从“展示数据”进一步定位经营问题。

Project 02 | FinPilot · AI 零基预算 Copilot

定位：AI Product / LLM 应用开发

微信小程序上的 AI 零基预算 Copilot。收入先进入 Budget Bucket，消费时由规则引擎计算预算状态，LLM 负责自然语言解析与解释。


收入分仓 → 自然语言记账 → 结构化解析 → 规则计算 → 审批 / 提示 → 用户确认 → 入账 → 月度分析

GitHub: <https://github.com/SomeH-Bosx/FinPilot>

Product Model



System



AI 边界

模块	责任
LLM	自然语言解析、审批理由、月度分析文案
Rule Engine	金额、预算剩余、审批状态
Pydantic	Structured Output 约束
Fallback	heuristic / 模板兜底

让模型负责理解与表达，让代码负责数字与状态。

2026-09 · 本月支出

¥0.00

已连接

展开

本月收入

¥0.00

可支配剩
余

¥0.00

超支仓

0 个

尚未登记本月收入，去零基分仓

用一句话记一笔消费

「午饭沙县 18」

开始记账

预算仓剩余

日常吃喝

剩 ¥0

— 未分配

已用 0%

娱乐

剩 ¥0

— 未分配

已用 0%

首页

预算仓

流水

分析

15:41

记一笔消费

已连接

展开

备注

备注 (可) 已连接 展开

原文：今天滴滴打车23

审批结论

通过

仓剩余 (前) ¥100.00
若确认后剩余 ¥77.00
预算仓custom_bucket
剩余金额充足，可批准
支出。

确认记录 (通过)

取消

15:40

记一笔消费

已连接

展开

说点什么，我来解析并审批
额度

今天午饭肯德基30

试试：今天滴滴 23 / 买书 59

AI 解析中 (约数十秒)

快速规划解析 (不同 LLM)

核心亮点

- 领域模型：Budget Bucket / Account 分离。
- AI 边界：LLM 不直接修改金额和审批状态。
- 可切换模型：LLMProvider Adapter 支持 Ollama / 通义 / DeepSeek。
- 可靠性：Structured Output + Pydantic + LLM 失效兜底。
- 端到端闭环：分仓、记账、审批、流水、月度分析贯通。


核心难点

难点	解决方案
LLM 幻觉影响财务数据	数字与 status 全部代码计算
本地 LLM 响应慢	规则 / 模板优先，云端模型可切换
“昨天晚饭”等相对时间	相对日期 + 餐次规则 + reference_now
真机鉴权与联调	wx.login → Bearer

Project 03 | Enterprise RAG · 企业文档知识库问答系统

- 定位：RAG / AI 应用开发 / Agent 基础能力
- 本地优先的企业文档问答系统：多格式入库 → Hybrid Retrieval → Rerank → LLM Generation → Sources / Trace。
- GitHub: <https://github.com/SomeH-Bosx/enterprise-rag>
- Tech Stack: LangChain · Chroma · BM25 · RRF · DashScope Rerank · Ollama · FastAPI · Streamlit · Docker

Architecture



Retrieval Pipeline

1	Query
2	↓
3	Router → 闲聊直答
4	↓
5	Rewrite
6	↓
7	Dense + BM25

8	↓
9	RRF Hybrid
10	↓
11	Reranker
12	↓
13	Context
14	↓
15	Local LLM
16	↓
17	Answer + Sources + Trace

Evaluation

通过公平消融验证检索策略：固定 **Hybrid@20** 候选后比较 RRF Top-5 与 Reranker Top-5。

配置	Recall@5	Strict Citation (filename, page)
Hybrid@10 / 20 / 30	83.33%	62.07%
Hybrid@20 + Reranker	86.67%	75.86%

Enterprise RAG · Phase5 Evaluation

来源 `evaluation/phase5/candidate_k` • 30 题

CONFIGURATION	RECALL@5	STRICT CITATION
Hybrid@10	83.33%	62.07%
Hybrid@20	83.33%	62.07%
Hybrid@30	83.33%	62.07%
Hybrid@20 + Reranker	86.67%	75.86%

30 题离线召回 (Top-5 计分) ; Strict Citation = `(filename, page)` 同时匹配。Hybrid@10/20/30 召回质量相同; 加入 Reranker 后 Recall@5 83.33%→86.67%, 严格引用 62.07%→75.86%。默认服务: Hybrid@20 + Reranker(Top-5)。详见 `docs/eval.md`。

Answer Trace

回答轨迹

查询分析

问题类型: `knowledge_query`

路由方式: `rules`

原问: `According to`

`acme_employee_handbook.pdf, how many annual leave days do ACME full-time employees get?`

改写问: `acme full-time employees annual leave days according to acme_employee_handbook.pdf`

改写方法: `llm`

检索模式: `Hybrid (Dense+BM25)`

Hybrid (BM25): `开`

检索

检索器: `Hybrid (Dense + BM25 RRF)`

Top-K = `20` · candidates=20

切块可能在句中截断（按字符分割）；块间 overlap 可减轻上下文丢失。

> **#1 acme_employee_handbook.pdf**
· page=1 · chunk conf 82%

> **#2 offer先生春招求职一本通**
PDF.pdf · page=76 · chunk conf 51%

#3 迪士尼乐园——东京迪士尼解

> 析-中英文版.pptx · page=24 · chunk
conf 48%

> #4 offer先生春招求职一本通
PDF.pdf · page=85 · chunk conf 51%

#5 迪士尼乐园——东京迪士尼解
> 析-中英文版.pptx · page=17 · chunk
conf 48%

#6 附件7：广东技术师范大学学生
> 手册（2023年3月版）.pdf ·
page=29 · chunk conf 50%

#7 迪士尼乐园——东京迪士尼解
> 析-中英文版.pptx · page=30 · chunk
conf 47%

> #8 offer先生春招求职一本通
PDF.pdf · page=78 · chunk conf 50%

重排

重排器: DashScope Reranker

选用: Top5

> #1 acme_employee_handbook.pdf
· page=1 · chunk conf 87%

#2 附件7：广东技术师范大学学生

#2 附件7：广东技术师范大学学生

> 手册（2023年3月版）.pdf ·
page=29 · chunk conf 29%

#3 附件7：广东技术师范大学学生

> 手册（2023年3月版）.pdf ·
page=33 · chunk conf 29%

#4 附件7：广东技术师范大学学生

> 手册（2023年3月版）.pdf ·
page=31 · chunk conf 29%

#5 附件7：广东技术师范大学学生

> 手册（2023年3月版）.pdf ·
page=34 · chunk conf 29%

生成

LLM: `ollama:qwen2.5:7b`

Response Generated

置信度

82%

等级: High

retrieval=0.8342 · rerank=0.7512 ·

source_coverage=1.0 · grounding=0.92

$0.25 \times 0.834(\text{retrieval_cal}) +$

$0.5 \times 0.751(\text{rerank}) +$

$0.1 \times 1.000(\text{source}) +$

$0.15 \times 0.920(\text{grounding}) = 0.822$

> 原始 Trace（安全字段）

核心亮点

Hybrid Retrieval: Dense + BM25 + RRF。

Reranker: 二阶段排序，避免盲目扩大召回。

Router / Rewrite: 区分知识库问答与闲聊，Rewrite 只服务检索。

Memory: 按 `conversation_id` 持久化并控制历史窗口。

多格式入库: PDF / Office / Markdown / TXT，并处理表格与可选 OCR。

工程化: FastAPI + Streamlit + Docker，支持 Session 级配置与 Trace。

核心难点

评测公平性: 避免候选宽度差异污染 Rerank 对比。

Fusion 截断: RRF 后稳定截断 `recall_k`，避免 `candidate_count` 漂移。

部署拓扑: Docker 中正确访问 Ollama，而不是直接使用 `127.0.0.1`。

Project 04 | 医疗 AI 细胞分类与模型优化

定位: 深度学习 / AI 算法 / 医疗图像分析

围绕 **巨幼样变细胞分类** 开展多模型实验、分类评估与细胞形态特征分析。

Dataset

8 类细胞，8:1:1 划分:

早 / 中 / 晚巨幼红细胞；巨中 / 巨晚幼粒细胞；巨分叶核粒细胞；巨杆状核粒细胞；巨核细胞巨幼变。

Models

- 1 | ResNet50 · DenseNet161 · ConvNeXt · EfficientNetV2
- 2 | ViT-S · DeiT-S · SwinV2-T · Nest-T

Multimodal Features

结合视觉模型与视觉语言模型，对细胞形态进行结构化描述：

细胞体积 · 核质比例 · 染色质 · 核仁数量 · 胞质染色强度

Evaluation

Accuracy · Per-class Accuracy · ROC · Confusion Matrix · SHAP

项目主要体现 模型训练、结构对比、分类评估、错误分析与多模态特征分析 能力。

Capability Map

能力方向	技术 / 方法
AI 应用	Python · FastAPI · LangChain · Ollama · Docker · SQLite · Taro
RAG / Agent	Embedding · BM25 · RRF · Reranker · Router · Rewrite · Memory · Trace · Evaluation
数据分析	Python · SQL · Power BI · RFM · 指标体系 · Dashboard
深度学习	PyTorch · CNN · ViT · 图像分类 · ROC · Confusion Matrix · SHAP

Engineering Practice

Git / GitHub：Branch · Merge · Rebase · Conventional Commits · PR · Reset / Revert。

AI Coding：使用 ChatGPT / Cursor / Claude Code 辅助编码、调试、重构和文档整理，并通过运行验证、测试和人工审查完成迭代。

1 | AI 生成 → 人工理解 → 运行验证 → 发现问题 → 修改 → 测试 → 沉淀

Appendix | Links

- Enterprise RAG： <https://github.com/SomeH-Bosx/enterprise-rag>
- FinPilot： <https://github.com/SomeH-Bosx/FinPilot>
- html2img-tool： <https://someh-bosx.github.io/html2img-tool/>

Contact

HUO BOXS · AI Application · RAG / Agent · Deep Learning · Data Analysis