

HUO BOXS · AI & Data Portfolio



AI 应用开发 | RAG / Agent | 深度学习 | 数据分析

信计专业本科生，持续通过项目实践 AI 应用工程、LLM/RAG、深度学习与数据分析。
关注 产品闭环、系统可靠性、可验证性与工程落地。

Selected Projects

项目	求职方向	核心能力
Enterprise RAG	AI 应用 / RAG / Agent	Hybrid Retrieval · Rerank · Evaluation · FastAPI · Ollama · Docker
FinPilot	AI 应用 / AI Product	LLM · Structured Output · Rule Engine · Taro · FastAPI
电商经营数据分析	数据分析 / BI	Python · SQL · Power BI · RFM · Dashboard
医疗 AI 细胞分类	AI 算法 / 深度学习	PyTorch · CNN / ViT · 多模型实验 · 模型评估

Project 01 | Enterprise RAG

企业文档知识库问答系统

定位：RAG / AI 应用开发 / Agent 基础能力

本地优先的企业文档问答系统：


多格式入库 → Hybrid Retrieval → Rerank → LLM Generation → Sources / Trace

GitHub: <https://github.com/SomeH-Bosx/enterprise-rag>


Tech Stack


LangChain · Chroma · BM25 · RRF · DashScope Rerank · Ollama · FastAPI · Streamlit · Docker

System Architecture



Retrieval Pipeline





Evaluation | 让 RAG “可验证”

针对 Rerank 做公平消融：固定 **Hybrid@20** 候选，仅比较 RRF Top-5 与 Reranker Top-5。

配置	Recall@5	Strict Citation (filename, page)
Hybrid@10 / 20 / 30	83.33%	62.07%
Hybrid@20 + Reranker	86.67%	75.86%

Enterprise RAG · Phase5 Evaluation

来源 `evaluation/phase5/candidate_k` • 30 题

CONFIGURATION	RECALL@5	STRICT CITATION
Hybrid@10	83.33%	62.07%
Hybrid@20	83.33%	62.07%
Hybrid@30	83.33%	62.07%
Hybrid@20 + Reranker	86.67%	75.86%

30 题离线召回 (Top-5 计分) ; Strict Citation = (filename, page) 同时匹配。Hybrid@10/20/30 召回质量相同；加入 Reranker 后 Recall@5 83.33%→86.67%，严格引用 62.07%→75.86%。默认服务：Hybrid@20 + Reranker(Top-5)。详见 `docs/eval.md`。

实验结论： 当前测试集上，继续扩大 Hybrid 候选数量没有提升 Top-5；Reranker 带来了更高的排序与引用质量。

Answer Trace

回答轨迹

查询分析

问题类型: `knowledge_query`

路由方式: `rules`

原问: `According to`

`acme_employee_handbook.pdf, how many annual leave days do ACME full-time employees get?`

改写问: `acme full-time employees annual leave days according to acme_employee_handbook.pdf`

改写方法: `llm`

检索模式: `Hybrid (Dense+BM25)`

Hybrid (BM25): `开`

检索

检索器: `Hybrid (Dense + BM25 RRF)`

Top-K = `20` · candidates=20

切块可能在句中截断（按字符分割）；块间 overlap 可减轻上下文丢失。

> **#1 acme_employee_handbook.pdf**
· page=1 · chunk conf 82%

> **#2 offer先生春招求职一本通**
PDF.pdf · page=76 · chunk conf 51%

#3 迪士尼乐园——东京迪士尼解

> 析-中英文版.pptx · page=24 · chunk
conf 48%

> #4 offer先生春招求职一本通
PDF.pdf · page=85 · chunk conf 51%

#5 迪士尼乐园——东京迪士尼解
> 析-中英文版.pptx · page=17 · chunk
conf 48%

#6 附件7：广东技术师范大学学生
> 手册（2023年3月版）.pdf ·
page=29 · chunk conf 50%

#7 迪士尼乐园——东京迪士尼解
> 析-中英文版.pptx · page=30 · chunk
conf 47%

> #8 offer先生春招求职一本通
PDF.pdf · page=78 · chunk conf 50%

重排

重排器: DashScope Reranker

选用: Top5

> #1 acme_employee_handbook.pdf
· page=1 · chunk conf 87%

#2 附件7：广东技术师范大学学生

#2 附件7：广东技术师范大学学生

> 手册（2023年3月版）.pdf ·
page=29 · chunk conf 29%

#3 附件7：广东技术师范大学学生

> 手册（2023年3月版）.pdf ·
page=33 · chunk conf 29%

#4 附件7：广东技术师范大学学生

> 手册（2023年3月版）.pdf ·
page=31 · chunk conf 29%

#5 附件7：广东技术师范大学学生

> 手册（2023年3月版）.pdf ·
page=34 · chunk conf 29%

生成

LLM: `ollama:qwen2.5:7b`

Response Generated

置信度

82%

等级: High

retrieval=0.8342 · rerank=0.7512 ·

source_coverage=1.0 · grounding=0.92

$0.25 \times 0.834(\text{retrieval_cal}) +$

$0.5 \times 0.751(\text{rerank}) +$

$0.1 \times 1.000(\text{source}) +$

$0.15 \times 0.920(\text{grounding}) = 0.822$

> 原始 Trace（安全字段）

Router / Rewrite / Retrieval / Rerank / Generation 全链路可观测，并返回 Sources 与置信度分解。

Engineering Highlights

Hybrid Retrieval

Dense + BM25 经 RRF 融合，Session 可切换 Dense / BM25 / Hybrid。

Reranker

二阶段排序，重点解决“相关内容已经召回，但 Top-5 排序不佳”的问题。

Query Router + Rewrite

将知识库问答与闲聊分流；Rewrite 只服务检索，生成仍使用原始问题。

Memory + Session

按 `conversation_id` 持久化消息，以有限历史窗口控制 Prompt 长度。

多格式入库

支持 PDF / Office / Markdown / TXT，处理表格与可选 OCR。

工程化部署

FastAPI + Streamlit + Docker，并处理 Docker → Ollama 的网络拓扑问题。

Core Challenge

最大的工程问题不是“把组件接起来”，而是证明组件为什么应该这样组合。

因此重点处理了三件事：

- 1 公平评测
- 2 ↓
- 3 定位真正瓶颈
- 4 ↓
- 5 确定默认 Pipeline

最终默认管线为：

Hybrid@20 → Reranker@5 → Local LLM

Project 02 | FinPilot

AI 零基预算 Copilot

定位：AI Product / LLM 应用开发

微信小程序上的 AI 零基预算 Copilot。
核心不是“再做一个记账工具”，而是让预算在消费发生前具备可执行的额度约束。

收入分仓 → 自然语言记账 → 结构化解析 → 规则计算 → 审批 / 提示 → 用户确认 → 入账 → 月度分析

GitHub: <https://github.com/SomeH-Bosx/FinPilot>

Product Model

1	Budget Bucket	Account
2	“能不能花”	“从哪里付”
3	↓	↓
4	日常 / 购物 / 储蓄 / 其他	微信 / 支付宝 / 其他

将 Budget Bucket 与 Account 分离，避免把“支付方式”直接当成“预算分类”。

System

1	Taro 小程序
2	↓
3	FastAPI
4	├ ExpenseExtract LLM
5	↓
6	Structured Output
7	↓
8	├ Rule Engine
9	└ 剩余 / approve / warn / reject
10	
11	├ 零基平衡校验
12	
13	└ Monthly Analysis
14	↓
15	SQLite

AI Boundary

模块	责任
LLM	自然语言解析、审批理由、月度分析文案
Rule Engine	金额、预算剩余、审批状态
Pydantic	Structured Output 约束
Fallback	heuristic / 模板兜底

让模型负责理解与表达，让代码负责数字与状态。



Engineering Highlights

- 领域模型：Bucket / Account 分离。
- 可靠性：Structured Output + Pydantic + LLM 失效兜底。
- 模型切换：LLMProvider Adapter 支持 Ollama / 通义 / DeepSeek。
- 端到端闭环：分仓、记账、审批、流水、月度分析贯通。

Core Challenge

问题	处理方式
LLM 幻觉影响财务状态	金额、仓剩余、status 全部代码计算
本地 LLM 响应慢	规则 / 模板优先，云端模型可切换
“昨天晚饭”等相对时间	相对日期 + 餐次规则 + reference_now
真机登录与联调	wx.login → Bearer 鉴权


Project 03 | 电商经营数据分析平台

定位：数据分析 / 商业分析 / BI


围绕电商经营数据完成：

数据清洗 → 指标体系 → 用户分析 → Power BI Dashboard → 经营洞察

Analysis Flow



Dashboard



RFM Analysis



维度	含义	分析问题
R	最近一次消费	用户是否仍活跃
F	消费频次	用户是否稳定消费
M	消费金额	用户价值贡献

Core Capabilities

数据处理：清洗、字段处理、分析数据集构建。

指标设计：经营、交易、用户维度指标拆解。

用户分析：RFM 用户价值分层。

BI 可视化：Overview、用户分析 Dashboard。

业务分析：从展示数据进一步定位经营问题。

Project 04 | 医疗 AI 细胞分类与模型优化

定位：AI 算法 / 深度学习 / 医疗图像分析

围绕 **巨幼样变细胞分类**开展多模型实验、分类评估与细胞形态特征分析。

Dataset

8 类细胞，8:1:1 划分

早 / 中 / 晚巨幼红细胞；

巨中 / 巨晚幼粒细胞；

巨分叶核粒细胞；

巨杆状核粒细胞；

巨核细胞巨幼变。

Model Experiments

- 1 ResNet50 · DenseNet161 · ConvNeXt · EfficientNetV2
- 2 ViT-S · DeiT-S · SwinV2-T · Nest-T

覆盖 CNN 与 Vision Transformer 等不同视觉架构。

Multimodal Features

结合视觉模型与视觉语言模型，对细胞形态进行结构化描述：

细胞体积 · 核质比例 · 染色质 · 核仁数量 · 胞质染色强度

Evaluation

Accuracy · Per-class Accuracy · ROC · Confusion Matrix · SHAP

项目体现：

模型训练 → 结构对比 → 性能评估 → 错误分析 → 多模态特征分析

Capability Map

AI Application

Python · FastAPI · LangChain · Ollama · Docker · SQLite · Taro
Structured Output · Pydantic · LLM Provider Adapter

RAG / Agent

Embedding · BM25 · RRF · Reranker · Query Router
Query Rewrite · Memory · Trace · Evaluation

Data Analysis

Python · SQL · Power BI · RFM · 指标体系 · Dashboard

Deep Learning

PyTorch · CNN · Vision Transformer · 图像分类
ROC · Confusion Matrix · SHAP · 多模态特征分析

Engineering Practice

Git / GitHub

Branch · Merge · Rebase · Conventional Commits · PR · Reset / Revert

AI Coding

使用 ChatGPT / Cursor / Claude Code 辅助编码、调试、重构与文档整理，并通过运行验证、测试和人工审查完成迭代。

```
1  AI 生成
2  ↓
3  人工理解
4  ↓
5  运行验证
6  ↓
7  发现问题
8  ↓
9  修改
10 ↓
11 测试
12 ↓
13 沉淀
```

Links

Enterprise RAG

<https://github.com/SomeH-Bosx/enterprise-rag>

FinPilot

<https://github.com/SomeH-Bosx/FinPilot>

html2img-tool

<https://someh-bosx.github.io/html2img-tool/>

HUO BOXS

AI Application · RAG / Agent · Deep Learning · Data Analysis

GitHub: [SomeH-Bosx](#)