

项目概览

项目	一句话介绍	技术栈	链接
EnterpriseRAG	企业知识库 RAG问答系统	LangChain/FastAPI/Chroma/Ollama/Docker	https://github.com/SomeH-Bosx/enterprise-rag
FinPilot	AI 零基础预算 Copilot (微信小程序)	Taro/FastAPI/SQLite/多模型Adapter	https://github.com/SomeH-Bosx/FinPilot
html2img-tool	HTML 转图片工具	Python/Tkinter/Playwright/JavaScript	https://someh-bosx.github.io/html2img-tool/

项目概览

企业文档 RAG 问答系统

简要概述

系统架构图

核心亮点

核心难点

FinPilot: AI 零基础预算 Copilot

简要概述

系统架构图

Demo截图

初始状态

正常使用状态

核心亮点

核心难点 & 怎么解

企业文档 RAG 问答系统

简要概述

技术栈： LangChain · Chroma · Ollama · BM25+RRF · DashScope Rerank · FastAPI · Streamlit · Docker

本地优先的企业文档 RAG： 多格式入库 → Hybrid 检索 + 语义重排 → 可引用生成；配套可解释 Trace、会话级配置，以及公平消融评测定稿默认管线。

- 建成端到端私有化 RAG：入库 → Hybrid 召回 → 重排 → 可引用生成 + Trace。

#1
> acme_employee_handbook.pdf · page=1 · chunk conf 80%

#2 offer先生春招求职一本通
> PDF.pdf · page=76 · chunk conf 52%

#3 迪士尼乐园——东京迪士尼
> 解析-中英文版.pptx · page=24 · chunk conf 48%

#4 offer先生春招求职一本通
> PDF.pdf · page=85 · chunk conf 52%

#5 迪士尼乐园——东京迪士尼
> 解析-中英文版.pptx · page=6 · chunk conf 48%

#6 offer先生春招求职一本通
> PDF.pdf · page=78 · chunk conf 51%

#7 迪士尼乐园——东京迪士尼
> 解析-中英文版.pptx · page=30 · chunk conf 47%

#8 附件7: 广东技术师范大学
> 学生手册 (2023年3月版) .pdf · page=33 · chunk conf 51%

重排
重排器: DashScope Reranker
选用: Top5

工作台对话

已开启多轮 Memory · 会话= a8554f87...

According to acme_employee_handbook.pdf, how many annual leave days do ACME full-time employees get?

According to acme_employee_handbook.pdf, ACME full-time employees get 15 days of annual leave.

route= knowledge_query · method= rules · model= 01lama:qwen2.5:7b · confidence= 83% (High) · elapsed= 36.7s · memory_msgs= 2

> 引用来源 (5)

询问你的知识库... ↑

2. 用公平消融证明：加宽候选不提升 Top-5；Rerank 将 Recall@5 从 83.3% 提到 86.7%，严格引用从 62.1% 提到 75.9%。

回答轨迹

查询分析

问题类型: knowledge_query

路由方式: rules

原问: According to

acme_employee_handbook.pdf, how
many annual leave days do ACME
full-time employees get?

改写问: acme full-time employees
annual leave days according to
acme_employee_handbook.pdf

改写方法: llm

检索模式: Hybrid (Dense+BM25)

Hybrid (BM25): 开

检索

检索器: Hybrid (Dense + BM25 RRF)

Top-K = 20 · candidates=20

切块可能在句中截断（按字符分割）；块
间 overlap 可减轻上下文丢失。

> #1 acme_employee_handbook.pdf
· page=1 · chunk conf 82%

> #2 offer先生春招求职一本通
PDF.pdf · page=76 · chunk conf 51%

> #3 迪士尼乐园——东京迪士尼解
析-中英文版.pptx · page=24 · chunk
conf 48%

> #4 offer先生春招求职一本通
PDF.pdf · page=85 · chunk conf 51%

> #5 迪士尼乐园——东京迪士尼解
析-中英文版.pptx · page=17 · chunk

析-中文版.pptx · page=17 · chunk
conf 48%

#6 附件7：广东技术师范大学学生

› 手册（2023年3月版）.pdf ·
page=29 · chunk conf 50%

#7 迪士尼乐园——东京迪士尼解

› 析-中英文版.pptx · page=30 · chunk
conf 47%

#8 offer先生春招求职一本通

› PDF.pdf · page=78 · chunk conf 50%

重排

重排器: DashScope Reranker

选用: Top5

#1 acme_employee_handbook.pdf

› · page=1 · chunk conf 87%

#2 附件7：广东技术师范大学学生

› 手册（2023年3月版）.pdf ·
page=29 · chunk conf 29%

#3 附件7：广东技术师范大学学生

› 手册（2023年3月版）.pdf ·
page=33 · chunk conf 29%

#4 附件7：广东技术师范大学学生

› 手册（2023年3月版）.pdf ·
page=31 · chunk conf 29%

#5 附件7：广东技术师范大学学生

› 手册（2023年3月版）.pdf ·
page=34 · chunk conf 29%

生成

LLM: `ollama:qwen2.5:7b`

Response Generated

置信度

82%

等级: High

retrieval=0.8342 · rerank=0.7512 ·

source_coverage=1.0 · grounding=0.92

$0.25 \times 0.834(\text{retrieval_cal}) +$
 $0.5 \times 0.751(\text{rerank}) +$
 $0.1 \times 1.000(\text{source}) +$
 $0.15 \times 0.920(\text{grounding}) = 0.822$

> 原始 Trace (安全字段)

3. 默认服务与评测结论对齐 (Hybrid@20 + Rerank@5) , 并提供 Session 级开关与可观测 Trace。


Enterprise RAG · Phase5 Evaluation

来源 `evaluation/phase5/candidate_k` · 30 题

CONFIGURATION	RECALL@5	STRICT CITATION
Hybrid@10	83.33%	62.07%
Hybrid@20	83.33%	62.07%
Hybrid@30	83.33%	62.07%
Hybrid@20 + Reranker	86.67%	75.86%

30 题离线召回 (Top-5 计分) ; Strict Citation = `(filename, page)` 同时匹配。Hybrid@10/20/30 召回质量相同; 加入 Reranker 后 Recall@5 83.33%→86.67%, 严格引用 62.07%→75.86%。默认服务: Hybrid@20 + Reranker(Top-5)。详见 `docs/eval.md`。

系统架构图



核心亮点

- 完整可上线的 RAG 产品形态，而不只是 Notebook Demo
FastAPI + Streamlit; 上传 / 问答 / 文档管理 / 健康检查; Docker 可部署。默认管线定稿为 Hybrid@20 → Reranker Top-5 → 本地 LLM 生成。
- 检索不是“堆组件”，而是有证据的设计选择
 - Dense + BM25 → RRF Hybrid, Session 可切 Dense / BM25 / Hybrid

- Phase5 公平消融（同候选 A/B + candidate_k∈{10,20,30}）证明：加宽召回到 30 不抬 Top-5；Rerank 才抬质量
- 数字化：

配置	Recall@5	Strict Citation (filename, page)
Hybrid@10/20/30	83.33%	62.07%
Hybrid@20 + Reranker	86.67%	75.86%

3. 可解释性：Answer Trace + 置信度

Router / Rewrite / 检索 / 重排 / 生成全链路可观测；返回 Sources 与置信度分解，“不是黑盒问答”。

4. 工程化分流与会话能力

- Query Router：知识库检索 vs 闲聊直答
- Query Rewrite 只改检索问、生成仍用原问
- Conversation Memory、Session 模型覆盖（不写 .env、密钥不落盘）
- 入库与本地优先

多格式（pdf/doc/docx/ppt/pptx/md/txt）、表格 Markdown、可选 OCR；生成与 Embedding 默认 Ollama。

核心难点

1. 评测公平性

早期“有/无 Rerank”对比其实混入了候选宽度差异（Top-5 vs ~Top-20），结论会被虚高。
做法：同一次 Hybrid@20 候选上做 A=RRF Top-5 / B=Rerank Top-5；并修正延迟口径（retrieve vs rerank 拆分）、引入 strict citation，避免 loose page 误判。

2. Hybrid 召回的真实瓶颈在哪

直觉是“再多召回一些就更好”。消融表明 Hybrid@10/20/30 的 Recall@5 完全相同，瓶颈在 Top-5 排序，因此默认采用 Rerank，而不是盲目加大 k。

3. 稀疏 + 稠密融合与截断策略

Dense/BM25 双路召回经 RRF 融合后必须稳定截断到 recall_k，否则 candidate_count 漂移会污染评测与线上行为。

4. 多格式入库的工程坑

Legacy Office 转换、docx 表格序列化、OCR 低文本页；Docker 下 Ollama 地址（127.0.0.1 vs host.docker.internal）会导致 Embedding 阶段 500——属于“链路通了但依赖拓扑错了”的典型部署问题。

5. 产品层可配置 vs 配置污染

检索模式 / Memory / Rewrite / 模型要可 Session 切换，又不能把演示态写回 .env；Trace 要足够细，又要做安全字段过滤。


FinPilot: AI 零基预算 Copilot

简要概述

FinPilot: 微信小程序上的 AI 零基预算 Copilot。收入 100% 分入预算仓，自然语言记消费，规则引擎审批额度（LLM 只解析与写文案），预算仓 ≠ 支付账户。

痛点：记账记全了仍超支——缺的是「事前额度」与「单笔能不能花」的决策，而不是又一个流水本。

系统架构图



初始状态



流水 · 9月1日 – 9月30日

筛选后支出 ¥0.00

筛选

当天

本月

按日选择起止日期，并可切换预算仓 / 支付账户，立即刷新

开始日期2026-09-01 >

结束日期2026-09-30 >

预算仓全部预算仓 >

支付账户全部账户 >

该条件下暂无流水

● 已连接

展开

月度预算分析

本月尚未登记收入。零基预算需要先分仓，才能做有意义的分析。

去登记收入并分仓

正常使用状态

15:40

🔒 记一笔消费

...

👁

说点什么，我来解析并审批额度

● 已连接

展开

今天午饭肯德基30

试试：今天滴滴 23 / 买书 59

AI 解析中 (约数十秒)

快速规则解析 (不依赖 LLM)

15:40

🔒 记一笔消费

...

👁

确认消费

● 已连接

展开

¥30.00

置信度 0.95

消费时间

9月4日 周五 12:00

日期：2026-09-04

时刻：12:00

08:00

12:00

19:00

22:00

预算仓：日常吃喝

账户：微信

商户 / 关键词

肯德基

备注

备注 (可选)

15:41

🔒 记一笔消费

...

👁

备注

备注 (可选)

● 已连接

展开

原文：今天滴滴打车23

审批结论

通过

仓剩余 (前) ¥100.00

若确认后剩余 ¥77.00

预算仓custom_bucket

剩余金额充足，可批准支出。

确认记录 (通过) ●

取消



核心亮点

#	亮点	一句话讲清
1	领域模型先行	拆分 Budget Bucket (能不能花) 与 Account (从哪付), 避免「微信=分类」的假预算。
2	AI 边界清晰	仅三项: NL 解析 / 审批文案 / 月度分析; 规则算数字与 status, 模型只写理由, 防幻觉改额度。
3	零基 + 强制储蓄	收入必 100% 分仓; 可支配 = 收入 - 储蓄; 非储蓄消费受 min(仓剩余, 可支配池) 约束。
4	工程可切换、可测	LLMProvider Adapter (Ollama / 通义 / DeepSeek); Structured Output + Pydantic; 黄金集 + 审批规则单测; LLM 挂了 heuristic/模板兜底。
5	端到端闭环	Taro 小程序: 分仓 → NL 确认卡 (含审批条) → 流水双标签 → 月度分析; wx.login + Bearer; 相对时间规则解析 (无日期词用记录时刻)。

相对「ChatGPT 套壳记账」的差异

常见做法	FinPilot
只会记流水	分仓控权 + 单笔审批
分类 = 支付方式	Bucket / Account 分离
模型直接说「能花」	规则定 approve/warn/reject, 模型写 reason
画像编占比	分析数字规则聚合, LLM 只写结论

核心难点 & 怎么解

难点	为什么难	做法
防 LLM 幻觉改账	模型爱「帮你决定能花多少」	status / 仓剩余 / 零基平衡全部代码锁定；LLM 只出文案；确认卡人工兜底；金额用分整数。
AI 能力边界怎么画	作品易做成万能 Agent，难测难讲	文档与代码写死仅三用途； <code>llm_calls.purpose</code> 三类；不做多工具链 Agent。
本地 LLM × 微信超时	Ollama 常 >30s，微信 request ≈60s 上限	解析/分析默认规则或模板秒开；云端再走 LLM；稳定优先。
相对时间解析	「昨天晚饭」易被记成当前时刻	规则引擎（相对日 + 餐次/时段）+ 客户端 <code>reference_now</code> ；无日期信号才用记录时刻；覆盖 LLM 的 <code>occurred_at</code> 。
储蓄强制 vs 自由消费	「想存却总动用」	储蓄仓锁定 + 可支配池； <code>收入-总支出 < 储蓄</code> 判定动用储蓄。
真机登录与联调	模拟器可 bypass，真机需鉴权	wx.login → Bearer；配 AppSecret 后拒 x-user-id；局域网 IP / 合法域名等部署约束写清。